UNIVERSITÉ DE MONTPELLIER

RAGForest - Développement d'un système de RAG basé sur un graphe de connaissances thématique

BOUZGARROU Sameur • M'HAMDA BOULOUDANI Salah-Eddine
MAHMOUD ALI Mahmoud • DJEBBAR Anis

Encadrants :
- Mme. Isabelle Mougenot
- M. Damien Arvor

— Mai 2026 —

LE PROBLÈME DE DÉPART

Posons une question simple à un LLM…

Comment Birmanie définit légalement une forêt?

LLM : *"selon les critères FAO, une forêt c'est 10% de couverture arborée, 5 mètres de hauteur, 0,5 hectare minimum."*

La réponse correcte :

Loi forestière 1992 :
→ définition purement juridique, aucun critère numérique

Protocole de Kyoto 2006 :
→ 1 ha · 20% couverture · 2 m hauteur

Plan de la présentation

01 **Grands modèles de langage (LLM)**

Fonctionnement & limites

02 **Architecture RAG**

Principes & limites du Vector RAG

03 **GraphRAG**

RDF · SKOS · Graphes de connaissances

04 **Construction du graphe**

Pipeline d'extraction · Modèle RDF/SKOS

05 **Apache Jena Fuseki & SPARQL**

Stockage · Endpoint · Requêtes

06 **Pipeline d'exécution**

LlamaIndex · few-shot · self-correction

07 **Test et Expérimentation**

LLM-as-Judge · Résultats · Leçons

Grands Modèles de Langage (LLM)

Architecture Transformer

1. Tokenisation du texte
2. Encodage en embeddings
3. Mécanisme d'Attention
4. Prédiction du token suivant

Apprentissage auto-supervisé

Milliards de paramètres entraînés sur de vastes corpus textuels

Modèle autorégressif

Chaque token prédit à partir du contexte précédent

Attention multi-têtes

Capture les dépendances à longue distance dans le texte

Limites des LLM : une illustration concrète

Hallucination

Le LLM remplace la définition birmane par les critères FAO génériques, sans signaler l'incertitude

Obsolescence des connaissances

Connaissances figées à la date de coupure — aucun accès aux évolutions légales récentes

Biais linguistique

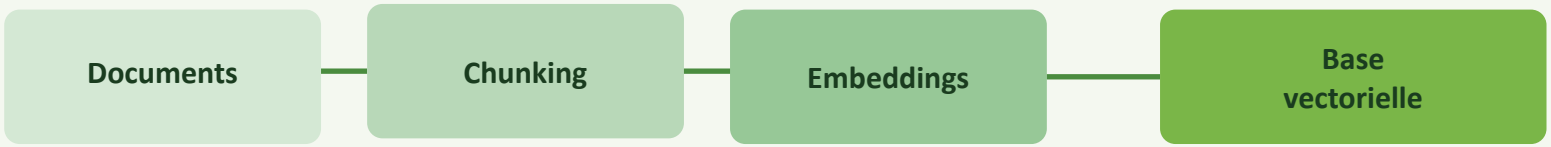
Sous-représentation des savoirs locaux (ex. communautés Karen) dans les corpus anglophones

Opacité (boîte noire)

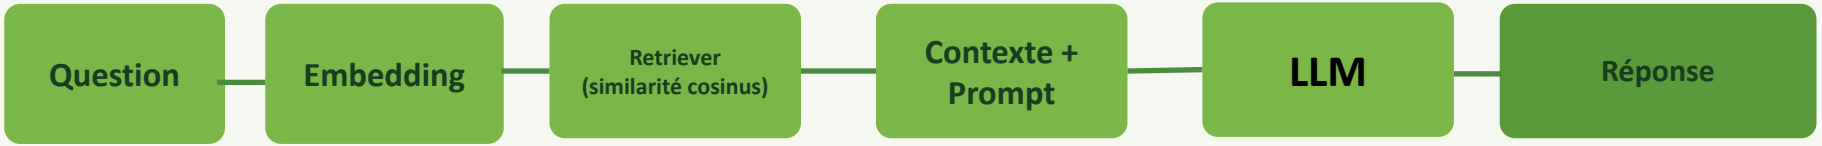
Impossible de tracer l'origine d'une affirmation — inacceptable dans un contexte scientifique

02 — Architecture RAG (Vector RAG)

PHASE 1 · INDEXATION (hors ligne)



PHASE 2 · RETRIEVAL + GÉNÉRATION (en ligne)



02 — Architecture RAG Vectoriel

Ce que le RAG Vectoriel apporte

- — Réduit les hallucinations
- — Données privées ou spécialisées
- — Mise à jour sans réentraînement
- — Architecture simple et éprouvée

Limites du RAG Vectoriel

- — Raisonnement local — fragment par fragment
- — Relations inter-entités ignorées
- — Redondance des fragments (chunks)
- — Perd la vision globale du corpus

GraphRAG · From Local to Global (Edge et al., 2024)

PHASE 1 · INDEXATION

1. **Corpus textuel**
   documents sources bruts
2. **Extraction entités & relations**
   via LLM → nœuds & arêtes
3. **Construction du graphe**
   agrégation des informations redondantes
4. **Détection de communautés**
   algorithme de Leiden → clusters thématiques

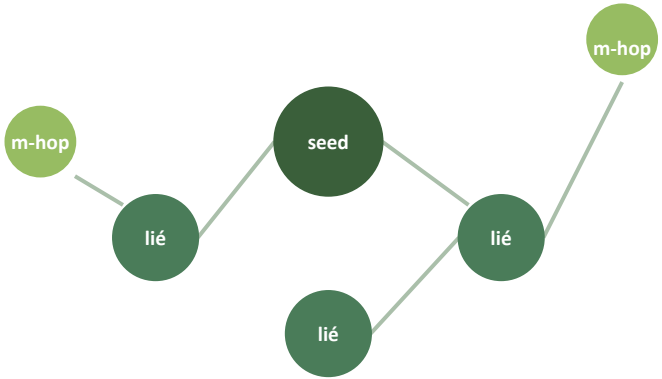
PHASE 2 · REQUÊTE

1. **Question utilisateur**
   interprétée comme requête structurée
2. **Exploration du graphe**
   navigation dans les communautés pertinentes
3. **Résumés de communautés**
   générés de manière ascendante (bottom-up)
4. **Réponse globale**
   agrégation hiérarchique des résumés

03 — KG2RAG · Approche hybride (Zhu et al., 2025)

1	2	3	4	5
Retrieval vectoriel	**Sous-graphe initial**	**Expansion BFS**	**MST filtering**	**Génération LLM**
top-k seed chunks	*extraction autour des seeds*	*m-hop sur le graphe*	*supprime redondances*	*contexte structuré*

Principe de l'expansion par graphe



- **Seed chunks :** *top-k par similarité vectorielle*
- **Nœuds liés :** *fragments factuellement liés (pas sémantiquement)*
- **m-hop (BFS) :** *expansion jusqu'à profondeur m dans le graphe*
- **MST final :** *arbre couvrant maximal — élimine la redondance*

03 — Web sémantique

RDF

Représenter les connaissances

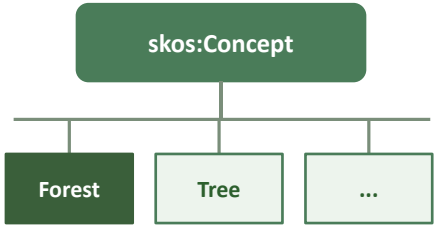



```
:def_Albania
:appliesIn  →  :Albania
```

— Chaque fait lié à sa source

SKOS

Organiser les concepts



— Chaque définition ancrée à son concept

SPARQL

Interroger le graphe

Question

▼

Requête SPARQL

▼

Réponse ancrée

Périmètre et Variabilité Normative

Le Corpus de Lund (2018)

Étude de **2 500+ définitions** normatives structurées autour de 5 termes clés : *Forêt, Arbre, Afforestation, Déforestation* et *Reforestation*.

L'Enjeu : Gérer la variabilité normative.
- FAO : 10% de couverture arborée.
- Afrique du Sud : 60% de couverture.

Le vocabulaire quasi-identique rend les systèmes vectoriels classiques inopérants, nécessitant un **graphe de connaissances**.

Modélisation RDF : Architecture

Le graphe articule le domaine forestier autour d'une séparation stricte entre concept abstrait et définition normative.

skos:Concept

L'entité conceptuelle abstraite servant de point d'ancrage central (ex: Forest).

:Definition

Instance spécifique portant le texte intégral et les seuils numériques.

:Jurisdiction

L'entité émettrice (Pays ou Organisation). 497 entités uniques.

:JurisdictionLevel

Échelle institutionnelle : Général, International, National, Local.

:InterpretationCategory

Angle d'interprétation : Administrative, LandCover, LandUse, Ecological.

Propriétés structurelles : *defines, appliesIn, hasCategory, hasJurisdictionLevel*

Normalisation et Puissance SPARQL

Normalisation Numérique

- **Standardisation :** Conversion automatique des unités (Pieds → Mètres, Acres → Hectares).
- **Stockage :** Typage en xsd:decimal pour permettre les opérateurs *FILTER* et *ORDER BY*.
- **Seuils :** Extraction des bornes inférieures comme valeurs effectives minimales.

Garanties du Modèle

- **Alignement Conceptuel :** Réconciliation explicite entre juridictions variées.
- **Comparaison Déterministe :** Interrogation des seuils physiques (couverture, hauteur).
- **Traçabilité :** Assertions reliées directement aux sources originales.
- **Interrogation déterministe** via SPARQL

"Le recours à SPARQL transforme un corpus textuel en base de données de connaissances interrogeable."

Pipeline d'Extraction Automatisée

Segmentation

Découpage du corpus en 3 307 paragraphes élémentaires.

Métadonnées

Extraction automatique de la juridiction et de l'année.

Normalisation

Traitement des seuils et conversion des unités standard.

Sourcing

Référencement source réussi pour 85% des définitions.

Attribution

Classification dans les catégories d'interprétation.

2 553
Définitions extraites

513
Juridictions uniques

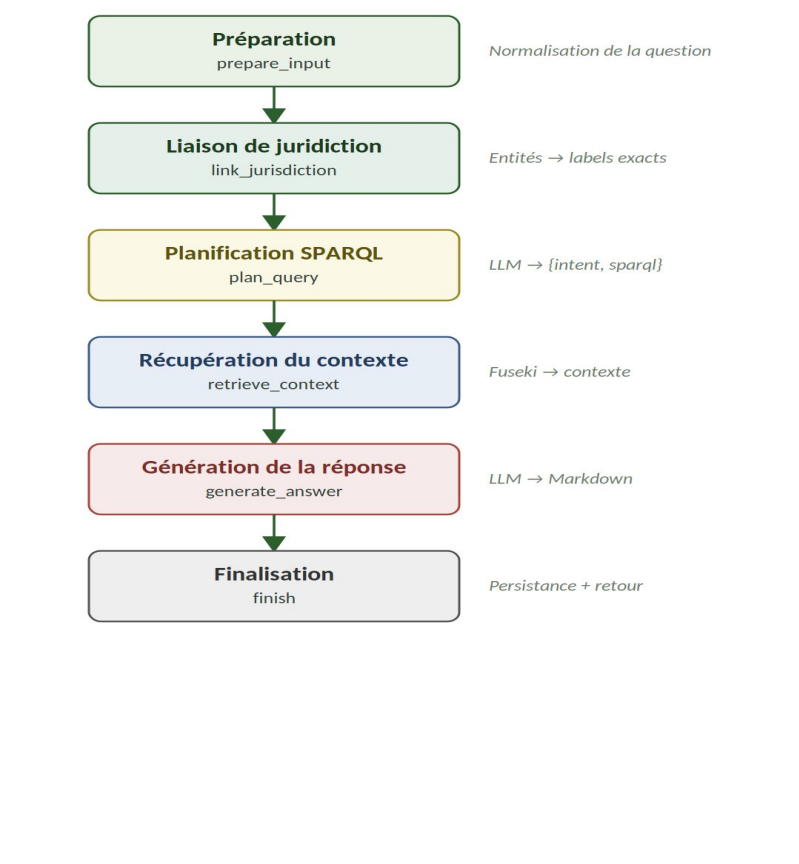
100%
Exploitable via SPARQL

Pipeline d'exécution — vue d'ensemble

Un workflow orchestré par LlamaIndex sous forme de DAG d'événements typés : 6 étapes isolées, traçables et testables, qui transforment une question en langage naturel en une réponse sourcée.

Pourquoi LlamaIndex ?

- Événements typés : chaque étape déclare son entrée et sa sortie, le flux de données est explicite et contrôlé.
- Asynchrone natif (asyncio) : les appels bloquants vers Fuseki et le LLM sont délégués sans alourdir la logique.
- Étapes isolées : on teste, on remplace ou on ajoute une étape sans casser le reste.



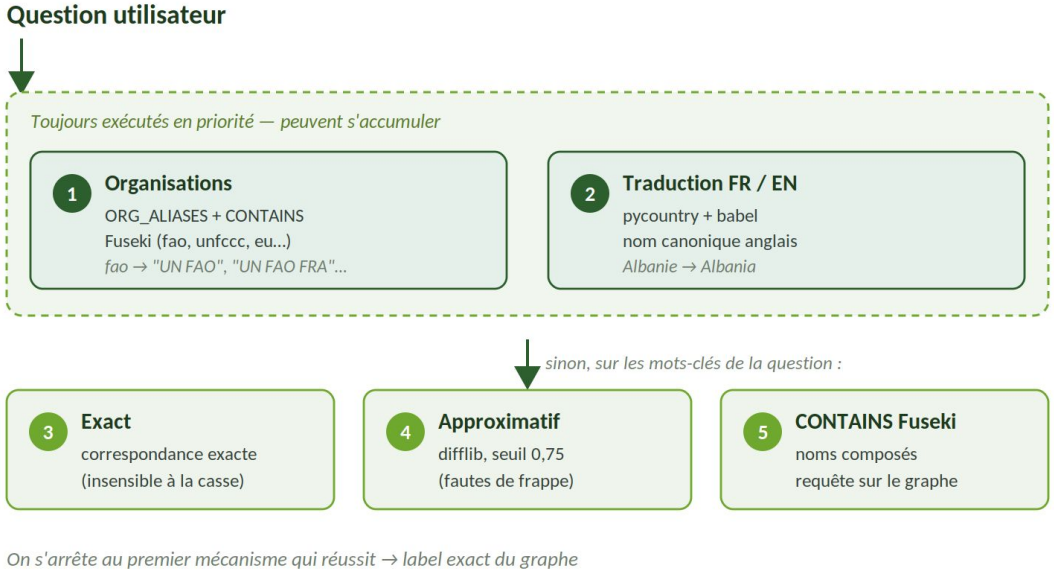
Comprendre la question avant de chercher

01 prepare_input — préparer l'entrée

- On nettoie la question et on rejette les entrées vides avant tout traitement.

02 link_jurisdiction

- L'utilisateur écrit « la FAO » ou « le Brésil » ; le graphe stocke des labels précis (« UN FAO FRA », « Brazil »).
- Il faut relier les entités aux labels exacts du graphe.
- 5 mécanismes en cascade — on s'arrête au premier qui réussit.
- Cette robustesse rattrape fautes de frappe, acronymes et noms en français.



Planifier la requête : un LLM qui écrit du SPARQL

03

plan_query — le LLM planificateur

- Premier des deux appels LLM. Rôle strictement délimité : traduire la question en requête exécutable.
- Sortie structurée JSON : { "intent": "...", "sparql": "..." }.
- L'intention est choisie parmi 9 types : définitionnel, comparatif, filtrage, synthèse, booléen, alignement, typologique, conceptuel, hors corpus.

!

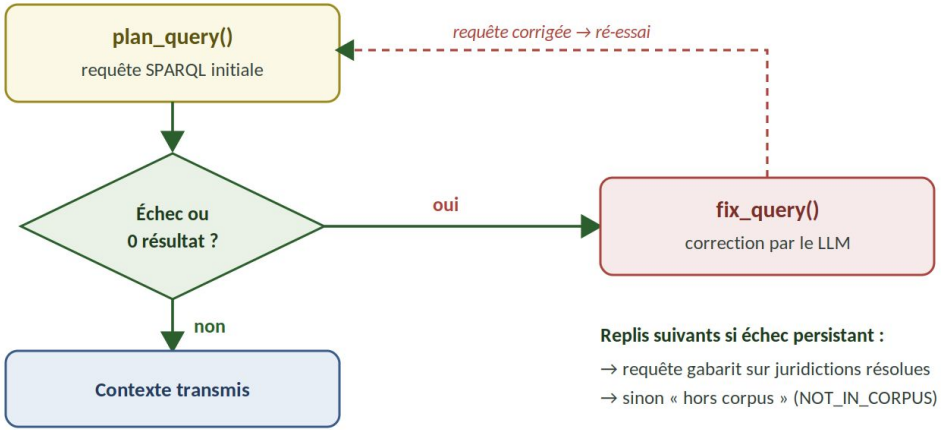
Choix technique — température 0.0

- Température fixée à 0.0 = sortie déterministe : la même question produit toujours la même requête.
- Pour générer du code, on ne veut aucune créativité, seulement fiabilité et reproductibilité.
- Conséquence directe : les résultats sont vérifiables et reproductibles par le jury.

Récupérer le contexte : la sécurité par les fallbacks

04 retrieve_context — exécution + garde-fous

- Une requête générée par une IA peut échouer ou ne rien renvoyer : on prévoit une cascade de filets de sécurité.



→

Principe

- fix_query : le LLM corrige lui-même la syntaxe de sa requête.
- Sinon : requête gabarit fiable sur les juridictions déjà résolues.
- En dernier recours : « hors corpus », sans appel LLM.
- On préfère un système qui avoue son ignorance à un système qui hallucine.

Générer la réponse, tracer, et délivrer la valeur

05 generate_answer — le LLM générateur

- Second appel LLM (Llama 3.3 70B, inférence < 200 ms). Rédige la réponse finale en Markdown, à partir du seul contexte récupéré.
- Deux modes : technique (temp 0.1) et grand public (temp 0.3) — d'où la séparation des deux appels LLM.

06 finish — sauvegarde et restitution

- Question, intention, requête et contexte sont sauvegardés : chaque réponse est auditable.

★ Impact du workflow

- Une question en langage naturel devient une réponse sourcée, fiable et traçable.
- Architecture modulaire et déterministe : la traçabilité de chaque assertion jusqu'à sa source est garantie.

Test et Expérimentation

Objectifs de l'évaluation

L'évaluation vise à quantifier la précision et la robustesse de l'architecture RAGForest à travers quatre piliers :

Fiabilité

Précision des seuils numériques et des faits réglementaires.

Robustesse LLM

Stabilité des performances entre différents modèles de langage.

Traçabilité

Lien direct et systématique vers la source du triplet.

Rejet Out-of-Corpus

Capacité à refuser les questions hors périmètre (NOT_IN_CORPUS).

Données d'évaluation

30 Questions de référence

Questions fournies par l'enseignant pour le raffinement itératif (v1, v2, v3).

50 Questions de validation étendue

Jeu de test final couvrant des concepts connexes (forestation, déforestation) et des cas hors corpus.

80

QUESTIONS ÉVALUÉES AU TOTAL

Détail de la Validation Étendue (50 Q)



Approche de Test et de Validation

Vérification

Objectif technique : S'assurer que chaque composant du pipeline fonctionne selon les spécifications.

- Liaison NERD exacte des juridictions mentionnées.
- Génération de requêtes SPARQL valides.
- Récupération effective des triplets RDF.

Validation

Objectif expérimental : Mesurer si les réponses finales sont correctes, sourcées et alignées avec le corpus.

- Pertinence métier et fidélité au corpus.
- Exactitude des seuils numériques extraits.
- Qualité de l'ancrage (Grounding) des sources.

Juge automatique : LLM-as-Judge

Protocole de notation (Claude Opus)

Le modèle **claude-opus-4-6** a été retenu pour sa supériorité en raisonnement logique et sa capacité à identifier les hallucinations subtiles.

Note	Statut	Critère
5	Validée	Réponse complète, sources correctes, raisonnement juste
4	Validée	Réponse correcte avec omissions mineures
3	Corrigée	Réponse partiellement correcte ou incomplète
2	Corrigée	Erreurs importantes, information partielle
1	Rejetée	Échec de retrieval, hallucination ou hors sujet



LLM-as-Judge

Échelle standardisée (1-5)

Itération 1 : Baseline (v1)

Défaillances initiales identifiées

- **Retrieval imprécis :** Filtre CONTAINS trop permissif ramenant du bruit (ex. Éthiopie pour fccc).
- **Hallucinations :** Confusion contextuelle par substitution (ex. EUDR vs EU 2013).
- **Routage faible :** Intentions non détectées pour Land Use et Land Cover.

2.62 / 5

NOTE MOYENNE (BASELINE V1)

8 / 30

VALIDÉES (SCORE 4-5)

11 / 30

REJETÉES (SCORE 1)

Techniques d'amélioration des résultats

Corrections ciblées après l'analyse des erreurs de la baseline v1.

Prompt Engineering

- **Few-shot prompting :** Ajout d'exemples de paires *question → JSON* dans le planner.
- **Self-correction :** La fonction fix_query() renvoie l'erreur au LLM pour corriger les requêtes.

Corrections SPARQL

- **Filtres stricts :** Remplacement des CONTAINS() par des filtres IN() exacts.

Retrieval & Refus

- **Reranking :** Bonus de 100 pour les juridictions mentionnées dans la question.
- **Refus direct :** Détection des entités absentes (ex: EUDR) via NOT_IN_CORPUS.

Impact attendu : Moins d'hallucinations + Meilleur grounding contextuel.

Itération 2 : Amélioration du retrieval (v2)

Applications de l'itération 2

- Filtres exacts ("UN FCCC", "UN FAO") éliminant 7 faux positifs.
- Support des questions conceptuelles sur les catégories RDF.
- Reranking par bonus fixe remplaçant le sac de mots.
- Transformation des 3 hallucinations en refus corrects (5/5).

Score moyen post-v2

3.69 / 5

PROGRESSION : +1,07 PT

Itération 3 : Spécialisation du requêtes (v3)

v1: Baseline — v2: Retrieval — v3: Spécialisation

Derniers raffinements

- **Requête dédiée Tree :** Ciblage direct du nœud conceptuel.
- **Retrieval dual-typologique :** Fusion pour questions comparatives.
- **Priorisation FAO :** Bonus pour les années de référence canoniques.

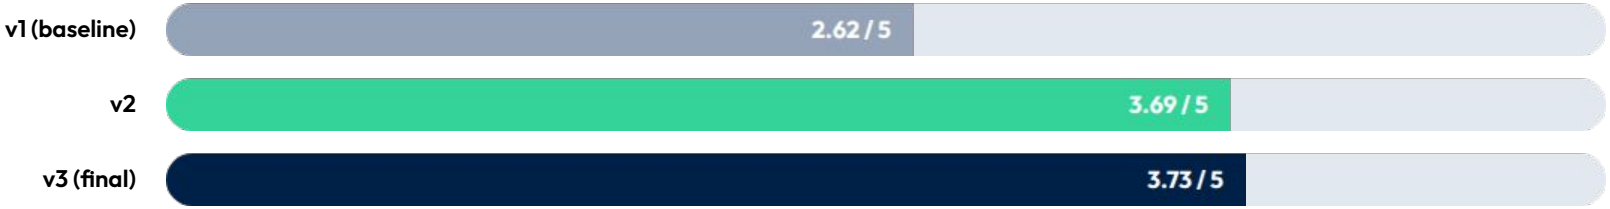
3.73 / 5

GAIN FINAL (+0.04 PT) • 18 VALIDÉES

⚠ Effet de bord

Le système rejette à tort la question générique "Qu'est-ce qu'une forêt ?" car trop stricte sur les entités.

Bilan des trois itérations (30 questions)



8 → 18
RÉPONSES VALIDÉES

11 → 1
RÉPONSES REJETÉES

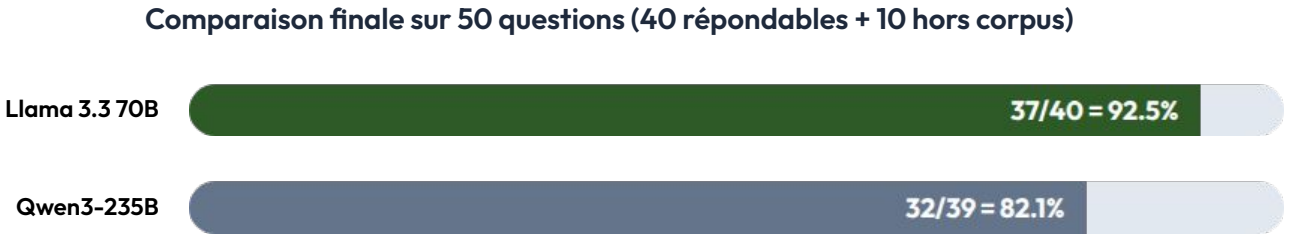
+1,11 pt
GAIN GLOBAL CUMULÉ

Validation sur d'autres modèles LLM

Modèle	Réponses /30	NOT_IN_CORPUS	Long. moy.	Latence moy.	Décision
Qwen3-235B	24 / 30	3	1767 car.	18,0 s	**Validateur final**
Llama 3.3 70B	23 / 30	4	1347 car.	17,9 s	**Moteur Retenu**
LLM léger 20B	23 / 30	4	1119 car.	29,4 s	Écarté

Synthèse : Llama 3.3 70B offre le meilleur compromis latence/qualité. Dans un pipeline GraphRAG à corpus strict, la précision du suivi d'instructions l'emporte sur la puissance brute.

Validation finale : Corpus étendu



Gestion Hors-Corpus

10 / 10

Refusées correctement par les deux modèles.

Note d'analyse

Les échecs résiduels relèvent principalement de lacunes du corpus Lund (2018), pas de l'architecture.

Résultats Finaux

92.5%

TAUX DE RÉUSSITE SUR LES QUESTIONS RÉPONDABLES DU CORPUS ÉTENDU

3.73 / 5 NOTE MOYENNE FINALE	**+1.11 pt** PROGRESSION TOTALE
18 / 30 VALIDÉES (CORPUS RÉF.)	**10 / 10** REFUS HORS CORPUS

Configuration validée : Pipeline v3 avec Llama 3.3 70B

Conclusion : Les erreurs restantes proviennent principalement des limites du corpus, pas de l'architecture informatique.

Limites du système



Dépendance au corpus actuel



Limites des LLMs utilisés



Absence de retours experts intégrés

Les limites restantes proviennent surtout du périmètre du corpus, des capacités des modèles utilisés et de l'absence d'un retour expert continu.

Perspectives et travaux futurs

1. Interface & retours experts

- Utiliser l'interface déjà implémentée
- Collecter les retours des experts

2. Nouveau corpus & graphe enrichi

- Intégrer un nouveau corpus
- Enrichir le graphe de connaissances

Objectif : améliorer RAGForest grâce aux retours experts et à l'enrichissement du graphe.

Répartition du travail

Quatre blocs de travail, chacun de nous a contribué à plusieurs d'entre eux. L'état de l'art a été mené à quatre.

Mahmoud

- État de l'art
- Pipeline d'extraction
- Tests et évaluation

Sameur

- État de l'art
- Implémentation du pipeline d'exécution
- Tests et évaluation

Anis

- État de l'art
- Pipeline d'extraction
- Implémentation du pipeline d'exécution

Salah

- État de l'art
- Implémentation du pipeline d'exécution
- Tests et évaluation (LLM-as-Judge, retours experts)

Outils utilisés pour gestion de projet :

- ClickUp
- Slack
- Gitlab

Merci Pour Votre Attention

